

MDI341

## Introduction aux modèles graphiques : réseaux bayésiens et modèles de Markov cachés

Mars 2017

Laurence Likforman-Sulem  
Telecom ParisTech/TSI  
bureau : E 504  
likforman@telecom-paristech.fr



## Plan

- Modèles graphiques
- Réseaux bayésiens
- Réseaux bayésiens dynamiques (DBN)
- Lien avec les HMMs (Hidden Markov Models)

## applications

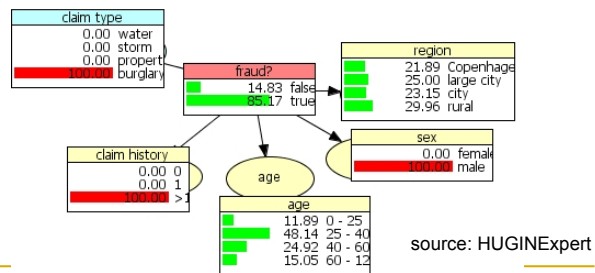
- HMMs et réseaux bayésiens dynamiques:

- reconnaissance de la parole,
- de l'écriture, détection d'objets,
- de visages dans les videos

- réseaux bayésiens statiques

- Détection de fraudes, ex: HUGIN
- diagnostic

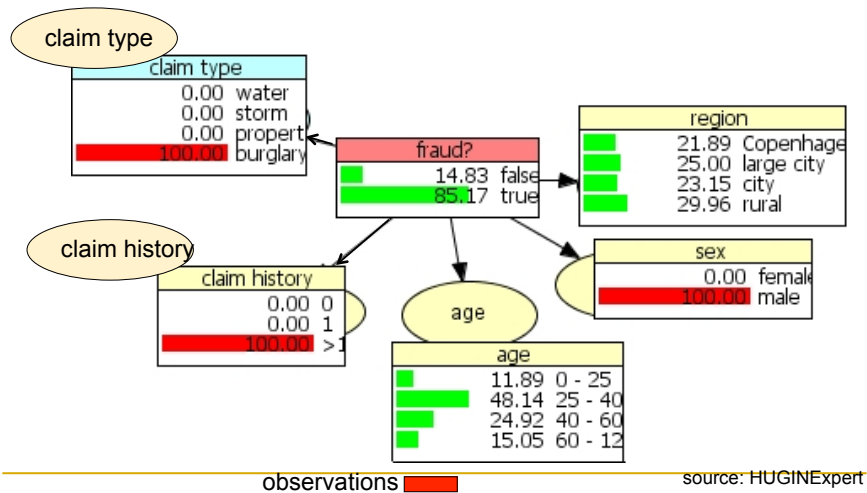
- observations



3

## Application: fraud detection

inférer les valeurs de variables non observées, à partir de variables observées




4


## Modèles graphiques: graphes non dirigés

- arbre : graphe non dirigé + 1 seul chemin entre 2 nœuds
- graphe multi-connexe : non dirigé + plusieurs chemins entre nœuds

Arbre simple



Graphe multi-connexe




5


## Modèles graphiques: graphes dirigés

- notion de fils, parents, descendants, ascendants, frères


Arbre simple  
(1 parent/variable)




Poly-arbre  
(1 seul chemin possible entre 2 nœuds, plusieurs parents possibles)



Graphe multi-connexe  
acyclique



Graphe cyclique




6

## réseau bayésien

- réseau bayésien:  $(G, \theta)$
- $G = (V, E)$  graphe acyclique orienté
  - $V$  : variables (nœuds),
  - $E$  : arcs: relations entre variables (influence d'une variable sur une autre)
- $\theta$  : paramètres (tables de probabilité locales)
  - $P(X|\text{parents}(X))$ ,  $P(X)$  si  $X$  n'a pas de parent
- réseau: encode la probabilité jointe de manière factorisée
  - apprentissage: moins de paramètres:  $1+1+4+2=8$  au lieu de  $2^4-1=15$
  - inférence moins complexe

$$P(A, B, C, D) = P(A)P(B)P(C|A, B)P(D|B)$$



7

## exemple réseau bayésien

[ from Wikipedia BN]

- $G$ : herbe du jardin humide (1 ou 0)
  - $S$ : arroseur en marche (1 ou 0)
  - $R$ : il a plu pendant la nuit (1 ou 0)
- 
- ```

graph TD
    R((R)) --> S((S))
    S --> G((G))
    R --> G
  
```
- $S \rightarrow G$  :  $G$  est une conséquence de  $S$
  - $R \rightarrow S$  :  $R$  a une influence sur  $S$  (s'il pleut, pas besoin de mettre en route l'arrosage)
  - $R \rightarrow G$  :  $G$  est une conséquence de  $R$
- réciproquement: la connaissance de  $G$  modifie la « croyance » de  $S$  et de  $R$  :  $P(R=1|G=1) > P(R=1)$

8


## paramètres d'un réseau bayésien

- tables de probabilités locales :  $P(X | \text{parents}(X))$
- Conditional Probability Tables or Distributions (CPT and CPD)
- G: herbe du jardin humide (1 ou 0)
- S: arroseur en marche (1 ou 0)
- R: il a plu pendant la nuit (1 ou 0)

| R | $P(S=1 R)$ | $P(S=0 R)$ |
|---|------------|------------|
| 0 | 0.4        | 0.6        |
| 1 | 0.01       | 0.99       |

| S | R | $P(G=0   S, R)$ | $P(G=1   S, R)$ |
|---|---|-----------------|-----------------|
| 1 | 1 | 0.01            | 0.99            |
| 1 | 0 | 0.1             | 0.9             |
| 0 | 1 | 0.2             | 0.8             |
| 0 | 0 | 1.0             | 0.0             |


$P(R=0)=0.8$   
 $P(R=1)=0.2$



9

## réseau bayésien: indépendance conditionnelle

- un nœud est indépendant de ses non-descendants connaissant ses parents
- C: le voisin appelle (1 ou 0)
- A: alarme maison s'est déclenchée (1 ou 0)
- B: il y a eu un cambriolage (1 ou 0)
- R: la radio annonce un tremblement de terre (1 ou 0)
- E: il y a un tremblement de terre (1 ou 0)




[d'après Nir Friedman]

- C est indépendant de R, B, E connaissant la valeur de A

10

## Bayesian network: mini TD

- exercice : calculer le nombre de paramètres de ce réseau




[from Nir Friedman]



11

## Inférence dans un réseau bayésien

- calcul de  $P(\text{variable(s)} \mid \text{variable(s) observée(s)})$
- variables observées: « evidence » ou observation
- inférence ou « propagation de l'observation »
- algorithmes d'inférence:
  - exacts dans arbres, polyarbres (passages de messages)
  - stochastiques : échantillonnage




12

## mini-TD : inférence

G observée :  $G=1$ , calculer  $P(R=1 | G=1)$

| R | $P(S=1 R)$ | $P(S=0 R)$ |
|---|------------|------------|
| 0 | 0.4        | 0.6        |
| 1 | 0.01       | 0.99       |

| S | R | $P(G=0 S,R)$ | $P(G=1 S,R)$ |
|---|---|--------------|--------------|
| 1 | 1 | 0.01         | 0.99         |
| 1 | 0 | 0.1          | 0.9          |
| 0 | 1 | 0.2          | 0.8          |
| 0 | 0 | 1.0          | 0.0          |



13

## inférence dans une chaîne

- 2 nœuds dont 1 observé  $\begin{array}{c} \text{X} \end{array} \longleftrightarrow \begin{array}{c} \text{Y} \end{array} \quad E = \{Y = y_2\}$   
 $\lambda(y)$

- paramètres:  $P(X=x)$  avec  $\text{dom}\{X\}=\{x_1, x_2\}$ , et  $P_{Y|X}$  avec  $\text{dom}\{Y\}=\{y_1, y_2, y_3\}$ ,

$$P_{Y|X} = \begin{bmatrix} P(Y=y_1|X=x_1) & P(Y=y_2|X=x_1) & P(Y=y_3|X=x_1) \\ P(Y=y_1|X=x_2) & P(Y=y_2|X=x_2) & P(Y=y_3|X=x_2) \end{bmatrix}$$

- variable backward  $\lambda$ :

$$\lambda(y) = P(E|Y=y) = [0 \quad 1 \quad 0]$$

$$\lambda(x) = P(E|X=x)$$


$$\text{on a } \lambda(x) = P_{Y|X} \lambda(y) = \begin{bmatrix} P(Y=y_2|X=x_1) \\ P(Y=y_2|X=x_2) \end{bmatrix}$$

on calcule  $\lambda(x)$  à partir du  
« message »  $\lambda(y)$   
envoyé par Y à X

$$P(X=x, E) = P(E=e|X=x)P(X=x) = \lambda(x)P(X=x)$$

14

## inférence dans une chaîne (backward)



4 nœuds dont 2 observés (Z et U), observations amont  $E^+$  et aval  $E^-$ :

$\text{dom}\{Z\} = \{z_1, z_2, z_3, z_4\}$

$\text{dom}\{U\} = \{u_1, u_2, u_3, u_4, u_5\}$

on pose variable backward  $\lambda(z) = P(E^- | Z = z) = [0 \ 0 \ 0 \ 1]$


on a  $\lambda(y) = P_{z|y} \lambda(z)$

et  $\lambda(x) = P_{y|x} \lambda(y)$

on calcule  $\lambda(y)$  à partir  
du message  $\lambda(z)$   
envoyé par Z à Y  
puis  $\lambda(x)$  à partir du  
message  $\lambda(y)$  envoyé  
par Y à X

15

## inférence dans une chaîne (forward)



4 nœuds dont 2 observés

on pose variable forward  $\pi(x) = P(X = x, E^+)$

on a  $\pi(u) = [0 \ 0 \ 0 \ 0 \ 1]$

on a  $\pi(x) = \pi(u) P_{x|u}$

et  $\pi(y) = \pi(x) P_{y|x}$

on calcule  $\pi(x)$  à partir  
du message  $\pi(u)$   
envoyé par U à son  
enfant X

$$P(X = x, E) = \lambda(x) \pi(x)$$

$$P(X = x | E) \propto \lambda(x) \pi(x)$$

facteur normalisation  $1/P(E)$  près

$$P(E) = \sum_{x \in \text{dom}\{X\}} \lambda(x) \pi(x)$$


16



## exemple (chaîne)

extrait de P. Naïm et al. Réseaux Bayésiens

S: sexe : F ou M  
D: daltonien: oui ou non



|     | D=oui | D=non |
|-----|-------|-------|
| S=F | 0.005 | 0.995 |
| S=M | 0,08  | 0.92  |

On observe :  $E = \{D = \text{oui}\}$  calculer par algorithme d'inférence (passage de message)  $P(S|E)$

quelle est la probabilité d'être une femme si on est daltonien ?


on considèrera que la proportion H/F est égale dans la population.

17

## inférence dans un arbre

• variables observées :  $X_1=2, X_4=1, X_5=1, X_6=2$


• variables cachées (états) :  $X_2, \text{dom}\{X_2\}=\{3,4,5\}$   $X_3, \text{dom}\{X_3\}=\{6,7\}$



18

## inférence dans les arbres

- $e_i^+$ : variables observées en amont de  $X_i$
- $e_i^-$ : variables observées en aval de  $X_i$
- $e_i^0$ : valeur observée de  $X_i$ , si  $X_i$  est observée
- $E = \{e_i^0, e_i^+, e_i^-\}$



19

## inférence dans les arbres

- on définit pour nœud  $X_i$

□ variable  $\lambda$  (backward)  $\lambda(x_i) = P(e_i^0, e_i^- | X_i = x_i)$

□ variable  $\pi$  forward  $\pi(x_i) = P(e_i^+, X_i = x_i)$

$$P(E, X_i = x_i) = P(e_i^0, e_i^-, e_i^+, X_i = x_i)$$

$$P(X_i = x_i, E) = \lambda(x_i) \pi(x_i)$$

$$P(E) = \sum_{x_i \in \text{dom}\{X_i\}} \lambda(x_i) \pi(x_i)$$

$$P(X_i = x_i | E) = \frac{\lambda(x_i) \pi(x_i)}{\sum_{x_i \in \text{dom}\{X_i\}} \lambda(x_i) \pi(x_i)} \propto \lambda(x_i) \pi(x_i)$$

20

### Algorithme d'inférence par passage de messages


message  $\lambda$  des enfants de  $X_i$ , à  $X_i$ :  $\lambda_{X_{c1}}(x_i)$

message  $\lambda$  de  $X_i$  à son parent  $X_p$ :  $\lambda_{X_i}(x_p)$

message  $\lambda$  des frères de  $X_i$  à leur parent  $X_p$ :  $\lambda_{X_{f2}}(x_p)$

message  $\pi$  envoyé par  $X_i$  à ses enfants:  $\pi_{X_{c1}}(x_i)$

message  $\pi$  envoyé à  $X_i$  par son parent  $X_p$ :  $\pi_{X_i}(x_p)$



21

### Algorithme d'inférence: calcul des $\lambda$

- les enfants  $X_{ci}$  envoient un message  $\lambda$  à leur parent  $X_i$ .

$$\lambda_{X_{c1}}(x_i) = P_{X_{c1}|X_i} \cdot \lambda(x_{c1})$$

- si  $X_i$  feuille observée  $\lambda(x_i) = [0 \ 1 \ 0]$  (position 1 dépend observation)

- si  $X_i$  feuille non observée:  $\lambda(x_i) = [1 \ 1 \ 1]$

- si  $X_i$  nœud (pas feuille) caché :

$$\lambda(x_i) = \prod_{Y: \text{children}(X_i)} \lambda_Y(x_i)$$

- avec  $\lambda_Y(x_i)$  message de l'enfant  $Y$  de  $X_i$ , à  $X_i$

- si  $X_i$  nœud (pas feuille) observé :  $\lambda(x_i) = \prod_{Y: \text{children}(X_i)} \lambda_Y(x_i)$  pour  $x_i$ =correspondant à l'observation, 0 sinon

22

## Algorithme d'inférence: calcul des $\pi$

- de la racine aux feuilles
- si  $X_i$  racine est observée  $\pi(x_i) = [0 \ 1 \ 0]$
- Si  $X_i$  est la racine, non observée  $\pi(x_i) = P(X_i = x_i)$
- sinon: on utilise le message  $\pi$  :  $\pi_{X_i}(x_p)$  envoyé à  $X_i$  par son unique parent  $X_p$ :

$$\pi(x_i) = \pi_{X_i}(x_p) P_{X_i|X_p}$$

$$\pi_{X_i}(x_p) = \pi(x_p) \prod_{Z, \text{frères de } X_i} \lambda_Z(x_p)$$


- messages  $\pi$  envoyés par  $X_i$  à chacun de ses enfants (message  $\lambda$  du ou des autres enfants et  $\pi$  du parent de  $X_i$ )

$$\pi_{X_{ci}}(x_i) = \prod_{X_f \text{ freres de } X_{ci}} \lambda_{X_f}(x_i) \quad \pi(x_i) = \prod_{X_f} \lambda_{X_f}(x_i) \pi_{X_i}(x_p) P_{X_i|X_p}$$

23

## inférence dans un réseau quelconque (DAG)

- convertir le réseau dans une structure d'arbre (arbre de jonction)
- algorithme d'inférence de l'arbre de jonction [Jensen, 96] [Zweig, 2003]
  - moralisation (connecter les parents)
  - triangulation (former des cliques)
  - connecter les cliques entre elles



24


## apprentissage des réseaux bayésiens

- apprentissage en données complètes, structure connue
  - estimation des paramètres  $P(\text{variable}|\text{Parents})$
  - par estimation au maximum de vraisemblance
- en données incomplètes, structure connue
  - algorithme EM ou descente de gradient ou méthodes stochastiques MCMC (échantillonnage de Gibbs)
- apprentissage de la structure, données complètes
  - algorithmes gloutons
- apprentissage de la structure, données incomplètes
  - EM + algorithmes gloutons

25


## extension: réseaux bayésiens dynamiques (DBN)

- modélisent des processus stochastiques stationnaires
  - structure & paramètres ne varient pas au cours du temps
  - plusieurs variables d'états et d'observations pour chaque pas de temps



26

## un modèle de Markov caché est un cas particulier de DBN



- HMM: Hidden Markov Model
- **structure d'arbre**
- **1 variable d'état + 1 variable d'observation à chaque instant t**

$(Q_t)_{1 \leq t \leq T}$  : variables d'état (cachées)

$(O_t)_{1 \leq t \leq T}$  : variables d'observation (observées) générées par les états

27

## références

- Wikipedia BN: [http://en.wikipedia.org/wiki/Bayesian\\_network](http://en.wikipedia.org/wiki/Bayesian_network)
- A. W. Moore, *Bayes Nets for representing and reasoning about uncertainty*, 2001
  - <http://www.cs.cmu.edu/%7Eawm/tutorials>
- S. Davis, A. Moore Bayesian networks: independencies and inference
  - <http://www.cs.cmu.edu/~awm/tutorials>
- K. Murphy, BayesNet Toolbox for matlab <https://code.google.com/p/bnt/>
- N. Friedman, D. Koller, Learning Bayesian Networks from data
- G. Zweig, Speech Recognition with Dynamic Bayesian Networks, Phd thesis, 1998, Univ. of California, Berkeley,
- P. Leray, Réseaux Bayésiens-Apprentissage de la structure
  - <http://asi.insa-rouen.fr/enseignants/~pleray/RB2003/2-ApprentissageStructure.pdf>
- P. Naïm, P-H. Willemin, P. Leray, O. Pourret, A. Becker, Les réseaux Bayésiens, Eyrolles, 2007.
- M. Sigelle, Bases de la Reconnaissance des Formes: Chaînes de Markov et Modèles de Markov Cachés, chapitre 7, Polycopié Telecom ParisTech, 2012.
- J. Pearl, Probabilistic Reasoning in intelligent systems: networks of plausible inference networks, 1988.
- L. Likforman-Sulem, E. Barney Smith, Reconnaissance des Formes: théorie et pratique sous matlab, Ellipses, TechnoSup, 2013.

28